

线性代数方程组的直接解法

郑春雄

清华大学数学科学系

czheng@tsinghua.edu.cn

基本问题

$A = (a_{ij}) \in \mathbf{R}^{n \times n}$, $b = (b_i) \in \mathbf{R}^n$. A 非奇异. 需要求解 $Ax = b$.

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & & & \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

基本问题

$A = (a_{ij}) \in \mathbf{R}^{n \times n}$, $b = (b_i) \in \mathbf{R}^n$. A 非奇异. 需要求解 $Ax = b$.

Theorem

*Cramer*法则: 存在唯一解 $x = (x_1, x_2, \dots, x_n)^T$

$$x_i = \frac{1}{\det A} \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1(i-1)} & b_1 & a_{1(i+1)} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2(i-1)} & b_2 & a_{2(i+1)} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{n(i-1)} & b_n & a_{n(i+1)} & \cdots & a_{nn} \end{vmatrix}$$

$$\det A = |A| = \sum_{j_1 j_2 \cdots j_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} a_{1j_1} a_{2j_2} \cdots a_{nj_n}.$$

基本问题

$A = (a_{ij}) \in \mathbf{R}^{n \times n}$, $b = (b_i) \in \mathbf{R}^n$. A 非奇异. 需要求解 $Ax = b$.

Theorem

Cramer法则: 存在唯一解 $x = (x_1, x_2, \dots, x_n)^T$

$$x_i = \frac{1}{\det A} \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1(i-1)} & b_1 & a_{1(i+1)} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2(i-1)} & b_2 & a_{2(i+1)} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{n(i-1)} & b_n & a_{n(i+1)} & \cdots & a_{nn} \end{vmatrix}$$

$$\det A = |A| = \sum_{j_1 j_2 \cdots j_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} a_{1j_1} a_{2j_2} \cdots a_{nj_n}.$$

计算量

$$(n+1) * n * n!$$

$n = 20$ 时为 $10^{21} = 10000 * 10^{17}$.

近似好坏的量化—残量(residual)

给定一个向量 x , 其残量定义为

$$r = r(x) = b - Ax.$$

相对残量:

$$\frac{\|r(x)\|}{\|r(0)\|} = \frac{\|r\|}{\|b\|}.$$

Outline

1 Action of Matrices

2 Gauss Elimination

3 Stability Analysis

矩阵的表示

- 方阵表示: matlab语法 $A = \text{zeros}(n, n)$

$$A = (a_{ij}) = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

- (元素)稀疏表示: $A = A(n, nz, row, col, val)$
 - n : 阶
 - nz : 非零元个数
 - row : 非零元行指标一维数组
 - col : 非零元列指标一维数组
 - val : 非零元值一维数组
- 其它结构表示

矩阵向量乘法

- 方阵表示: matlab语法 $y=A*x$

```
y=zeros(size(x));  
n=length(x);  
for i=1:n  
    for j=1:n  
        y(i)=y(i)+A(i,j)*x(j);  
    end  
end
```

- 稀疏表示: $A = A(n, nz, row, col, val)$

```
y=zeros(size(x));  
for m=1:nz  
    y(row(m))=y(row(m))+val(m)*x(col(m));  
end
```

含结构信息矩阵

思想出发点:

$$a \times c + b \times c = (a + b) \times c$$

低秩矩阵与向量乘法:

- 秩1矩阵 $A = (a_{ij})$, $A = uv^\dagger$, $a_{ij} = u_i v_j$:

$$y = Ax = (uv^\dagger)x = (v^\dagger x)u \rightarrow y_i = \sum_j a_{ij}x_j = \sum_j u_i v_j x_j = \left(\sum_j v_j x_j\right)u_i$$

- 奇异值分解与低秩逼近—内在稀疏性

$$A = U\Sigma V^* = \sum_i \lambda_i U_i V_i^*$$

其中 U 和 V 为酉阵

$$U = [U_1 \ U_2 \ \cdots U_n], \ V = [V_1 \ V_2 \ \cdots V_n],$$

$$\Sigma = \text{diag}(\sigma_1, \cdots, \sigma_n), \ \sigma_1 \geq \cdots \geq \sigma_n \geq 0.$$

矩阵的Hierarchical表示

矩阵没有内在稀疏性, 但非对角元有内在稀疏性: 即

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$$

但 A_{12} 和 A_{21} 内在稀疏

$$Ax = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} A_{11}x_1 + A_{12}x_2 \\ A_{21}x_1 + A_{22}x_2 \end{bmatrix}$$

其中 $A_{11}x_1$ 和 $A_{22}x_2$ 递归处理.

Discrete Fourier Transform (DFT)特殊矩阵:

$$F = (a_{kj}), \quad a_{kj} = \omega^{-kj}, \quad \omega = \exp(2\pi i/n), \quad k, j = 0, 1, \dots, n-1.$$

$$F = \begin{pmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & \omega^{-1 \times 1} & \omega^{-1 \times 2} & \dots & \omega^{-1 \times (n-1)} \\ 1 & \omega^{-2 \times 1} & \omega^{-2 \times 2} & \dots & \omega^{-2 \times (n-1)} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & \omega^{-(n-1) \times 1} & \omega^{-(n-1) \times 2} & \dots & \omega^{-(n-1) \times (n-1)} \end{pmatrix}$$

矩阵 F 中只有 n 个不同的元素! 比如当 $n=8$ 时,

$$F = \omega \cdot \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 7 & 6 & 5 & 4 & 3 & 2 & 1 \\ 0 & 6 & 4 & 2 & 0 & 6 & 4 & 2 \\ 0 & 5 & 2 & 7 & 4 & 1 & 6 & 3 \\ 0 & 4 & 0 & 4 & 0 & 4 & 0 & 4 \\ 0 & 3 & 6 & 1 & 4 & 7 & 2 & 5 \\ 0 & 2 & 4 & 6 & 0 & 2 & 4 & 6 \\ 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix}.$$

快速Fourier变换(FFT)的基本思想— $n = 8$

$$\begin{aligned}Y_{(j_2 j_1 j_0)} &= \sum_{k_0, k_1, k_2} X_{(k_2 k_1 k_0)} \omega^{-(j_2 j_1 j_0)(k_2 k_1 k_0)} \\&= \sum_{k_0, k_1, k_2} X_{(k_2 k_1 k_0)} \omega^{-j_0(k_2 k_1 k_0) - j_1(k_1 k_0 0) - j_2(k_0 0 0)} \\&= \sum_{k_0} \left(\sum_{k_1} \left(\sum_{k_2} X_{(k_2 k_1 k_0)} \omega^{-j_0(k_2 k_1 k_0)} \right) \omega^{-j_1(k_1 k_0 0)} \right) \omega^{-j_2(k_0 0 0)}\end{aligned}$$

$$X_{(j_0 k_1 k_0)} \leftarrow \sum_{k_2} X_{(k_2 k_1 k_0)} \omega^{-j_0(k_2 k_1 k_0)}$$

$$X_{(j_0 j_1 k_0)} \leftarrow \sum_{k_1} X_{(j_0 k_1 k_0)} \omega^{-j_1(k_1 k_0 0)}$$

$$X_{(j_0 j_1 j_2)} \leftarrow \sum_{k_0} X_{(j_0 j_1 k_0)} \omega^{-j_2(k_0 0 0)}$$

当 $n = 2^J$ 时, 计算量 $\mathcal{O}(nJ) = \mathcal{O}(n \log_2 n) = \mathcal{O}(n \ln n)$.

直接验证:

$$F^{-1} = (b_{kj}), \quad b_{kj} = n^{-1} \omega^{kj}.$$

因而

$$F^{-1} = n^{-1} \bar{F} = n^{-1} F^*.$$

FFT—非2的乘幂

显然

$$y_j = \sum_{k=0}^{n-1} x_k \omega^{-jk} = \sum_{k=0}^{n-1} x_k \omega^{\frac{-j^2 - k^2 + (j-k)^2}{2}}, \quad j \in [0, n).$$

定义

$$v_k = \omega^{\frac{k^2}{2}}, \quad k \in (-n, n), \quad z_k = x_k v_k^{-1}, \quad k \in [0, n),$$

则

$$y_j = v_j^{-1} \sum_{k=0}^{n-1} z_k v_{j-k}, \quad j \in [0, n).$$

设 $2n-1 \leq N = 2^J$. 以0拓展序列 x_k 和 v_k 并将其周期化, 周期为 N . 则

$$y_j = v_j^{-1} \sum_{k=0}^{N-1} z_k v_{j-k}, \quad j \in [0, n).$$

周期卷积的快速计算

需要快速计算

$$\alpha_j = \sum_{k=0}^{N-1} z_k v_{j-k}, \quad j \in [0, N).$$

两端做DFT:

$$\begin{aligned} \sum_{j=0}^{N-1} \alpha_j \omega_N^{-jm} &= \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} z_k v_{j-k} \omega_N^{-jm} \\ &= \sum_{k=0}^{N-1} z_k \omega_N^{-km} \sum_{j=0}^{N-1} v_{j-k} \omega_N^{-(j-k)m} \\ &= \sum_{k=0}^{N-1} z_k \omega_N^{-km} \sum_{j=0}^{N-1} v_j \omega_N^{-jm} \end{aligned}$$

α_j 的计算: 两次DFT, 一次向量分量积, 一次逆DFT.

周期Toeplitz变换

Theorem

n 阶矩阵 $A = (a_{kj})$ 若满足 $a_{kj} = c_{k-j}$, 并且 $\{c_k\}$ 是一个周期为 n 的序列, 则称该矩阵为周期 *Toeplitz* 矩阵. 周期 *Toeplitz* 矩阵通过 *DFT* 相似于对角矩阵. 即

$$A = F^{-1} \Lambda F,$$

其中 $\Lambda = \text{diag}(\lambda_0, \dots, \lambda_{n-1})$, 并且

$$\lambda_k = \sum_{m=0}^{n-1} \omega^{-km} c_m.$$

Proof.

记 $\Lambda = F A F^{-1} = (\lambda_{kj})$. 则 (Einstein summation convention)

$$\lambda_{kj} = n^{-1} \omega^{-km} c_{m-p} \omega^{pj} = n^{-1} \omega^{-k(m-p)} c_{m-p} \omega^{p(j-k)} = n^{-1} \omega^{-km} c_m \omega^{p(j-k)}.$$



Toeplitz变换

n 阶矩阵 $A = (a_{kj})$ 若满足 $a_{kj} = c_{k-j}$, 其中 $\{c_k\}_{k \in (-n, n)}$ 是一个有限序列, 则称该矩阵为Toeplitz矩阵.

$$y = Ax \longrightarrow \begin{bmatrix} y \\ * \end{bmatrix} = \begin{bmatrix} A & * \\ * & * \end{bmatrix} \begin{bmatrix} x \\ 0 \end{bmatrix}$$

将 n 阶Toeplitz矩阵 A 扩展成任意一个 $2n$ 阶周期Toeplitz矩阵 $\tilde{A}$

$$\tilde{A} = \begin{bmatrix} A & * \\ * & * \end{bmatrix}.$$

Outline

1 Action of Matrices

2 Gauss Elimination

3 Stability Analysis

几种易于求解的情况

- A 为对角阵. $x_i = b_i/a_{ii}$. 计算量 $O(n)$.
- A 为上三角阵.

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{2n} \\ 0 & 0 & a_{33} & \cdots & a_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & a_{nn} \end{bmatrix}$$

则 $x_n = b_n/a_{nn}$, $x_i = (b_i - \sum_{j=i+1}^n a_{ij}x_j)/a_{ii}$, $i = n-1, \dots, 1$. 计算量 $O(n^2)$.

- A 为正交阵. 则 $x = A^T b$. 计算量 $O(n^2)$. 特殊情况下, 如DFT变换等, 为 $O(n \ln n)$.

基本思路

将 $Ax = b$ 的求解问题转化为一个与之等价的易于求解的问题 $\tilde{A}\tilde{x} = \tilde{b}$.

$$\tilde{A} = LAU, \tilde{b} = Lb, x = U\tilde{x}.$$

初等变换矩阵

设 $\mathbf{u}, \mathbf{v} \in \mathbf{R}^n$, $\sigma \in \mathbf{R}$, 称

$$E(\mathbf{u}, \mathbf{v}; \sigma) \stackrel{\text{def}}{=} \mathbf{I} - \sigma \mathbf{u} \mathbf{v}^T$$

为实初等矩阵.

设 $\mathbf{u} = (u_1, u_2, \dots, u_n)^T$, $\mathbf{v} = (v_1, v_2, \dots, v_n)^T$, 则

$$\mathbf{u} \mathbf{v}^T = \begin{pmatrix} u_1 \\ u_2 \\ \dots \\ u_n \end{pmatrix} \begin{pmatrix} v_1 & v_2 & \dots & v_n \end{pmatrix} = \begin{pmatrix} u_1 v_1 & u_1 v_2 & \dots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \dots & u_2 v_n \\ \dots & \dots & \dots & \dots \\ u_n v_1 & u_n v_2 & \dots & u_n v_n \end{pmatrix}$$

初等变换矩阵

设 $\mathbf{u}, \mathbf{v} \in \mathbf{R}^n$, $\sigma \in \mathbf{R}$, 称

$$E(\mathbf{u}, \mathbf{v}; \sigma) \stackrel{\text{def}}{=} \mathbf{I} - \sigma \mathbf{u} \mathbf{v}^T$$

为实初等矩阵.

设 $\mathbf{u} = (u_1, u_2, \dots, u_n)^T$, $\mathbf{v} = (v_1, v_2, \dots, v_n)^T$, 则

$$\mathbf{u} \mathbf{v}^T = \begin{pmatrix} u_1 \\ u_2 \\ \dots \\ u_n \end{pmatrix} \begin{pmatrix} v_1 & v_2 & \dots & v_n \end{pmatrix} = \begin{pmatrix} u_1 v_1 & u_1 v_2 & \dots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \dots & u_2 v_n \\ \dots & \dots & \dots & \dots \\ u_n v_1 & u_n v_2 & \dots & u_n v_n \end{pmatrix}$$

$$\begin{aligned} E(\mathbf{u}, \mathbf{v}; \sigma) E(\mathbf{u}, \mathbf{v}; \tau) &= (\mathbf{I} - \sigma \mathbf{u} \mathbf{v}^T)(\mathbf{I} - \tau \mathbf{u} \mathbf{v}^T) \\ &= \mathbf{I} - \left(\sigma + \tau - \sigma \tau (\mathbf{v}^T \mathbf{u}) \right) \mathbf{u} \mathbf{v}^T, \end{aligned}$$

若能令 $\sigma + \tau - \sigma \tau (\mathbf{v}^T \mathbf{u}) = 0$, 即 $\tau = \frac{\sigma}{\sigma \mathbf{v}^T \mathbf{u} - 1}$, 则 $E(\mathbf{u}, \mathbf{v}; \sigma)^{-1} = E(\mathbf{u}, \mathbf{v}; \tau)$.
因而初等矩阵若可逆, 其逆也是 (同类型) 初等矩阵。

初等矩阵实例

若 $\mathbf{v}^T \mathbf{u} = 0$, 即 $\mathbf{u}$ 与 $\mathbf{v}$ 垂直, 则有 $\tau = -\sigma$,

$$E(\mathbf{u}, \mathbf{v}; \sigma)^{-1} = E(\mathbf{u}, \mathbf{v}; -\sigma).$$

$\det E(\mathbf{u}, \mathbf{v}; \sigma) = 1 - \sigma \mathbf{v}^T \mathbf{u}$. 原因在于 $\mathbf{u}\mathbf{v}^T$ 的所有特征值为0和 $\mathbf{v}^T \mathbf{u}$.

- 初等排列阵 $\mathbf{l}_{ij} \stackrel{\text{def}}{=} E(\mathbf{e}_i - \mathbf{e}_j, \mathbf{e}_i - \mathbf{e}_j; 1)$. 初等排列阵 $\mathbf{l}_{ij}$ 左乘一个矩阵表示将该矩阵的第 i 行和第 j 行互换. 初等排列阵 $\mathbf{l}_{ij}$ 右乘一个矩阵则表示将该矩阵的第 i 列和第 j 列互换. $\mathbf{l}_{ij}^{-1} = \mathbf{l}_{ij}$.
- $E(\mathbf{e}_j, \mathbf{e}_i; -\alpha) = \mathbf{I} + \alpha \mathbf{e}_j \mathbf{e}_i^T$ 左乘一个矩阵表示将该矩阵的第 i 行的 α 倍加到第 j 行上去. $E(\mathbf{e}_j, \mathbf{e}_i; -\alpha) = \mathbf{I} + \alpha \mathbf{e}_j \mathbf{e}_i^T$ 右乘一个矩阵表示将该矩阵的第 j 列的 α 倍加到第 i 列上去.

初等下三角阵

若记 $\mathbf{l}_j = (0, \dots, 0, l_{j+1,j}, \dots, l_{n,j})^T$, 其前 j 个分量为零. 令

$$L_j(\mathbf{l}_j) = E(\mathbf{l}_j, \mathbf{e}_j; -1) = \mathbf{I} + \mathbf{l}_j \mathbf{e}_j^T = \begin{pmatrix} 1 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \vdots & \vdots \\ 0 & \cdots & 1 & 0 & \cdots & 0 \\ 0 & \cdots & l_{j+1,j} & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & l_{n,j} & 0 & \cdots & 1 \end{pmatrix}$$

$L_j(\mathbf{l}_j)$ 左乘一个矩阵表示将 j 行的 $l_{k,j}$ 倍加到 k 行上去, k 从 $j+1$ 行到 n 行. 由于 $\mathbf{e}_j^T \mathbf{l}_j = 0$, 我们有 $L_j(\mathbf{l}_j)^{-1} = L_j(-\mathbf{l}_j)$.

当 $i \leq j$ 时, $L_i(\mathbf{l}_i)L_j(\mathbf{l}_j) = (\mathbf{I} + \mathbf{l}_i \mathbf{e}_i^T)(\mathbf{I} + \mathbf{l}_j \mathbf{e}_j^T) = \mathbf{I} + \mathbf{l}_i \mathbf{e}_i^T + \mathbf{l}_j \mathbf{e}_j^T$, 因而一个单位下三角阵可以写成

$$L = L_1(\mathbf{l}_1)L_2(\mathbf{l}_2)\cdots L_{n-1}(\mathbf{l}_{n-1}).$$

Gauss消去法

假设方程为

$$\begin{aligned}a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + a_{13}^{(1)}x_3 + \cdots + a_{1n}^{(1)}x_n &= b_1^{(1)} \\a_{21}^{(1)}x_1 + a_{22}^{(1)}x_2 + a_{23}^{(1)}x_3 + \cdots + a_{2n}^{(1)}x_n &= b_2^{(1)} \\a_{31}^{(1)}x_1 + a_{32}^{(1)}x_2 + a_{33}^{(1)}x_3 + \cdots + a_{3n}^{(1)}x_n &= b_3^{(1)} \\&\vdots \\a_{n1}^{(1)}x_1 + a_{n2}^{(1)}x_2 + a_{n3}^{(1)}x_3 + \cdots + a_{nn}^{(1)}x_n &= b_n^{(1)}.\end{aligned}$$

若 $a_{11}^{(1)} \neq 0$, 则可将第1行的 $-a_{21}^{(1)}/a_{11}^{(1)}$ 倍加到第2行上去, 得到一个新的方程, 不含有 x_1 变量

$$a_{22}^{(2)}x_2 + a_{23}^{(2)}x_3 + \cdots + a_{2n}^{(2)}x_n = b_2^{(2)}$$

同样可将第1行的 $-a_{31}^{(1)}/a_{11}^{(1)}$ 倍加到第3行上去, 得到一个新的方程, 不含有 x_1 变量

$$a_{32}^{(2)}x_2 + a_{33}^{(2)}x_3 + \cdots + a_{3n}^{(2)}x_n = b_3^{(2)}$$

如此一直到第 n 行

$$a_{n2}^{(2)}x_2 + a_{n3}^{(2)}x_3 + \cdots + a_{nn}^{(2)}x_n = b_n^{(2)}$$

于是我们得到与原方程组等价的一个新的方程组

$$\begin{aligned} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + a_{13}^{(1)}x_3 + \cdots + a_{1n}^{(1)}x_n &= b_1^{(1)} \\ a_{22}^{(2)}x_2 + a_{23}^{(2)}x_3 + \cdots + a_{2n}^{(2)}x_n &= b_2^{(2)} \\ &\vdots \\ a_{n2}^{(2)}x_2 + a_{n3}^{(2)}x_3 + \cdots + a_{nn}^{(2)}x_n &= b_n^{(2)}. \end{aligned}$$

如果 $a_{22}^{(2)} \neq 0$, 上述处理过程显然可以类似考虑. 我们可以得到一个新的 等价的线性代数方程组

$$\begin{aligned}a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + a_{13}^{(1)}x_3 + \cdots + a_{1n}^{(1)}x_n &= b_1^{(1)} \\a_{22}^{(2)}x_2 + a_{23}^{(2)}x_3 + \cdots + a_{2n}^{(2)}x_n &= b_2^{(2)} \\a_{33}^{(3)}x_3 + \cdots + a_{3n}^{(3)}x_n &= b_3^{(3)} \\a_{nn}^{(n)}x_n &= b_n^{(n)}.\end{aligned}$$

如果 $a_{33}^{(3)} \neq 0$, 上述处理可以继续直到最后一个方程只含有变量 x_n ,

$$\begin{aligned}a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + a_{13}^{(1)}x_3 + \cdots + a_{1n}^{(1)}x_n &= b_1^{(1)} \\a_{22}^{(2)}x_2 + a_{23}^{(2)}x_3 + \cdots + a_{2n}^{(2)}x_n &= b_2^{(2)} \\a_{33}^{(3)}x_3 + \cdots + a_{3n}^{(3)}x_n &= b_3^{(3)} \\a_{nn}^{(n)}x_n &= b_n^{(n)}.\end{aligned}$$

这样我们便将原问题转化为一个系数矩阵为上三角阵的线性代数方程组的求解问题.

Gauss消去法的计算量

在消去第 k 个变量过程中,我们必须做 $n-k$ 次除法, $(n+1-k)(n-k)$ 次乘法和减法,因而在整个消去过程中,乘除法次数为

$$\sum_{k=1}^{n-1} (n-k) + \sum_{k=1}^{n-1} (n+1-k)(n-k) = \frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6},$$

加减法次数为

$$\sum_{k=1}^{n-1} (n+1-k)(n-k) = \frac{n^3}{3} - \frac{n}{3},$$

而回代过程乘除法次数为 $\frac{n(n+1)}{2}$,加减法次数为 $\frac{n(n-1)}{2}$,所以 Gauss消去法总的乘除法次数为

$$\frac{n^3}{3} + n^2 - \frac{n}{3} \approx \frac{n^3}{3},$$

总的加减法次数为

$$\frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6} \approx \frac{n^3}{3},$$

因而Gauss消去法的算法复杂度为 $\frac{n^3}{3}$,其中 n 为线性代数方程组的规模.

矩阵的LU分解

记

$$\mathbf{A}^{(k)} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1k-1}^{(1)} & a_{1k}^{(1)} & a_{1k+1}^{(1)} & \cdots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2k-1}^{(2)} & a_{2k}^{(2)} & a_{2k+1}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{k-1k-1}^{(k-1)} & a_{k-1k}^{(k-1)} & a_{k-1k+1}^{(k-1)} & \cdots & a_{k-1n}^{(k-1)} \\ 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & a_{kk+1}^{(k)} & \cdots & a_{kn}^{(k)} \\ 0 & 0 & \cdots & 0 & a_{k+1k}^{(k)} & a_{k+1k+1}^{(k)} & \cdots & a_{k+1n}^{(k)} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & a_{nk+1}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}$$

$$\mathbf{b}^{(k)} = (b_1^{(1)}, b_2^{(2)}, \dots, b_{k-1}^{(k-1)}, b_k^{(k)}, b_{k+1}^{(k)}, \dots, b_n^{(k)})^T,$$

$$\mathbf{l}_k = (0, 0, \dots, 0, 0, a_{k+1k}^{(k)}/a_{kk}^{(k)}, \dots, a_{nk}^{(k)}/a_{kk}^{(k)})^T$$

则由如上的过程可知

$$\mathbf{A}^{(k+1)} = L_k(-\mathbf{l}_k)\mathbf{A}^{(k)}, \mathbf{b}^{(k+1)} = L_k(-\mathbf{l}_k)\mathbf{b}^{(k)}.$$

因而有

$$\begin{aligned}\mathbf{A}^{(n)} &= L_{n-1}(-\mathbf{l}_{n-1})L_{n-2}(-\mathbf{l}_{n-2})\cdots L_1(-\mathbf{l}_1)\mathbf{A}^{(1)}, \\ \mathbf{b}^{(n)} &= L_{n-1}(-\mathbf{l}_{n-1})L_{n-2}(-\mathbf{l}_{n-2})\cdots L_1(-\mathbf{l}_1)\mathbf{b}^{(1)}.\end{aligned}$$

进一步,

$$\mathbf{A}^{(1)} = L_1(\mathbf{l}_1)L_2(\mathbf{l}_2)\cdots L_{n-1}(\mathbf{l}_{n-1})\mathbf{A}^{(n)}.$$

令 $\mathbf{L} = L_1(\mathbf{l}_1)L_2(\mathbf{l}_2)\cdots L_{n-1}(\mathbf{l}_{n-1})$, $\mathbf{U} = \mathbf{A}^{(n)}$, 则 $\mathbf{L}$ 为单位下三角阵(即对角线元素为单位1的下三角阵), $\mathbf{U}$ 为上三角阵.

三角分解定理

Theorem

(三角分解)非奇异矩阵 $\mathbf{A} \in \mathbf{R}^{n \times n}$, 若其顺序主子式

$$\Delta_i \stackrel{\text{def}}{=} \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ a_{21} & a_{22} & \cdots & a_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ii} \end{vmatrix}, \quad i = 1, 2, \dots, n$$

均不为零, 则存在唯一的单位下三角阵 $\mathbf{L}$ 和上三角阵 $\mathbf{U}$, 使 $\mathbf{A} = \mathbf{LU}$.

三角分解定理

Theorem

(三角分解)非奇异矩阵 $\mathbf{A} \in \mathbf{R}^{n \times n}$, 若其顺序主子式

$$\Delta_i \stackrel{\text{def}}{=} \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ a_{21} & a_{22} & \cdots & a_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ii} \end{vmatrix}, \quad i = 1, 2, \dots, n$$

均不为零, 则存在唯一的单位下三角阵 $\mathbf{L}$ 和上三角阵 $\mathbf{U}$, 使 $\mathbf{A} = \mathbf{LU}$.

Proof.

$$\mathbf{A} = \mathbf{L}_1 \mathbf{U}_1 = \mathbf{L}_2 \mathbf{U}_2, \mathbf{L}_2^{-1} \mathbf{L}_1 = \mathbf{U}_2 \mathbf{U}_1^{-1}.$$

上式左边为一单位下三角阵(直接计算), 左边为一上三角阵, 因而

$$\mathbf{L}_2^{-1} \mathbf{L}_1 = \mathbf{U}_2 \mathbf{U}_1^{-1} = \mathbf{I}.$$

直接LU分解

矩阵 $\mathbf{A}$ 的所有顺序主子式都非零,则有唯一的三角分解 $\mathbf{A} = \mathbf{LU}$,其中 $\mathbf{L}$ 为单位下三角阵, $\mathbf{U}$ 为上三角阵.

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ l_{21} & 1 & 0 & \cdots & 0 \\ l_{31} & l_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & 1 \end{pmatrix}, \text{共 } n(n-1)/2 \text{ 个未知变量}$$

$$\mathbf{U} = \begin{pmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ 0 & 0 & u_{33} & \cdots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & u_{nn} \end{pmatrix}, \text{共 } n(n+1)/2 \text{ 个未知变量}$$

两矩阵中的未知变量个数为 n^2 与矩阵 $\mathbf{A}$ 的元素个数一致,因而可以直接由矩阵 $\mathbf{A}$ 确定 $\mathbf{L}$ 和 $\mathbf{U}$.

记 $\mathbf{A}^{(n)} = \mathbf{A}$. 设 $\mathbf{A}^{(k)} = \mathbf{L}^{(k)}\mathbf{U}^{(k)}$ 其中

$$\mathbf{L}^{(k)} = \begin{pmatrix} 1 & 0 \\ l_{n-k+1} & \mathbf{L}^{(k-1)} \end{pmatrix}, \quad \mathbf{U}^{(k)} = \begin{pmatrix} u_{n-k+1, n-k+1} & u_{n-k+1}^T \\ 0 & \mathbf{U}^{(k-1)} \end{pmatrix}.$$

于是

$$\mathbf{A}^{(k)} = \mathbf{L}^{(k)}\mathbf{U}^{(k)} = \begin{pmatrix} u_{n-k+1, n-k+1} & u_{n-k+1}^T \\ u_{n-k+1, n-k+1}l_{n-k+1} & \mathbf{A}^{(k-1)} + l_{n-k+1}u_{n-k+1}^T \end{pmatrix}.$$

- 确定 u ;
- 确定 l ;
- 更新 $\mathbf{A}$, 阶减少1.

Cholesky分解

Theorem

设 A 为实对称正定, 则存在唯一的对角元素为正的下三角矩阵 L , 使得

$$A = LL^{\dagger}.$$

加边Cholesky分解法:

$$\begin{bmatrix} A_{i-1} & c \\ c^{\dagger} & a_{ii} \end{bmatrix} = \begin{bmatrix} L_{i-1} & 0 \\ h^{\dagger} & l_{ii} \end{bmatrix} \begin{bmatrix} L_{i-1}^{\dagger} & h \\ 0 & l_{ii} \end{bmatrix} = \begin{bmatrix} L_{i-1}L_{i-1}^{\dagger} & L_{i-1}h \\ * & h^{\dagger}h + l_{ii}^2 \end{bmatrix}$$

因而

$$\begin{aligned} L_{i-1}h &= c, \\ l_{ii}^2 &= a_{ii} - h^{\dagger}h. \end{aligned}$$

主元技巧(pivoting technique)

回忆Gauss消去法.如果在第 k 步, $a_{kk}^{(k)} = 0$, 则Gauss消去法不能继续下去.即便 系数矩阵 $\mathbf{A}$ 非奇异,理论上方程组存在唯一解亦是如此. 此外,即便在消去过程中, $a_{kk}^{(k)} \neq 0$,但是如果 $|a_{kk}^{(k)}| \ll 1$,则会产生大数除以小数的情况,导致 数值解的精度下降,有时更会完全失真.看如下例子
用3位十进制浮点运算求解

$$\begin{aligned}1.00 \times 10^{-5}x_1 + 1.00x_2 &= 1.00, \\1.00x_1 + 1.00x_2 &= 2.00.\end{aligned}$$

解: 这个方程组的准确解用3位十进制浮点数近似为 $(1.00, 1.00)^T$.

$$\begin{aligned}\begin{pmatrix} 1.00 \times 10^{-5} & 1.00 \\ 1.00 & 1.00 \end{pmatrix} &\rightarrow \begin{pmatrix} \boxed{1.00 \times 10^{-5}} & \boxed{1.00} \\ \boxed{1.00 \times 10^5} & 1.00 \end{pmatrix} \\ &\rightarrow \begin{pmatrix} \boxed{1.00 \times 10^{-5}} & \boxed{1.00} \\ \boxed{1.00 \times 10^5} & \boxed{-1.00 \times 10^5} \end{pmatrix}\end{aligned}$$

第一步求解 $\mathbf{L}\mathbf{y} = \mathbf{b}$,得到 $\mathbf{y} = (1.00, -1.00 \times 10^5)^T$. 第二步求解 $\mathbf{U}\mathbf{x} = \mathbf{y}$,得到 $\mathbf{x} = (0.00, 1.00)^T$.

列主元方法

如上所述困难有一自然的解决方案:即在第 k 步消去之前,选择

$$a_{kk}^{(k)}, a_{k+1k}^{(k)}, \dots, a_{nk}^{(k)}$$

模值最大者,将其所在的行与第 k 行交换,然后进行消去过程. 设其所在的行数为 $i_k \geq k$, 则 加入如上处理过程后,我们有

$$\mathbf{A}^{(k+1)} = L_k(-l_k) \mathbf{I}_{i_k k} \mathbf{A}^{(k)}.$$

记 $\mathbf{U} = \mathbf{A}^{(n)}$, 则

$$\mathbf{U} = L_{n-1}(-l_{n-1}) \mathbf{I}_{i_{n-1} n-1} \cdots L_2(-l_2) \mathbf{I}_{i_2 2} L_1(-l_1) \mathbf{I}_{i_1 1} \mathbf{A}$$

于是

$$\mathbf{A} = \mathbf{I}_{i_1 1} L_1(l_1) \mathbf{I}_{i_2 2} L_2(l_2) \cdots \mathbf{I}_{i_{n-1} n-1} L_{n-1}(l_{n-1}) \mathbf{U}$$

一般三角分解定理

设 $\mathbf{A}$ 非奇异,则存在排列阵 $\mathbf{P}$,单位下三角阵 $\mathbf{L}$ 和上三角阵 $\mathbf{U}$,使得

$$\mathbf{PA} = \mathbf{LU}.$$

一般三角分解定理

设 $\mathbf{A}$ 非奇异,则存在排列阵 $\mathbf{P}$,单位下三角阵 $\mathbf{L}$ 和上三角阵 $\mathbf{U}$,使得

$$\mathbf{PA} = \mathbf{LU}.$$

令

$$\mathbf{P} = \mathbf{l}_{i_{n-1}n-1} \cdots \mathbf{l}_{i_2 2} \mathbf{l}_{i_1 1}, \quad \mathbf{P}_k = \mathbf{l}_{i_{n-1}n-1} \cdots \mathbf{l}_{i_k k},$$

有

$$\mathbf{P}_k^T \mathbf{P}_{k+1} = \mathbf{l}_{i_k k}.$$

则

$$\begin{aligned} \mathbf{PA} &= \mathbf{l}_{i_{n-1}n-1} \cdots \mathbf{l}_{i_2 2} L_1(\mathbf{l}_1) \mathbf{l}_{i_2 2} L_2(\mathbf{l}_2) \cdots \mathbf{l}_{i_{n-1}n-1} L_{n-1}(\mathbf{l}_{n-1}) \mathbf{U} \\ &= \mathbf{P}_2 L_1(\mathbf{l}_1) \mathbf{P}_2^T \mathbf{P}_3 L_2(\mathbf{l}_2) \mathbf{P}_3^T \mathbf{P}_4 L_3(\mathbf{l}_3) \cdots \mathbf{P}_{n-1}^T L_{n-1}(\mathbf{l}_{n-1}) \mathbf{U} \\ &= L_1(\mathbf{P}_2 \mathbf{l}_1) L_2(\mathbf{P}_3 \mathbf{l}_2) \cdots L_{n-2}(\mathbf{P}_{n-1} \mathbf{l}_{n-2}) L_{n-1}(\mathbf{l}_{n-1}) \mathbf{U}. \end{aligned}$$

Thomas方法

求解如下的方程

$$\begin{bmatrix} b_1 & c_1 & & & 0 \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & \cdot & \\ & & \cdot & \cdot & c_{n-1} \\ 0 & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdot \\ \cdot \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \cdot \\ \cdot \\ d_n \end{bmatrix}$$

LU分解算法:

for k=2 step until n do

$$a_k \leftarrow \frac{a_k}{b_{k-1}}$$

$$b_k \leftarrow b_k - a_k c_{k-1}$$

end loop (k)

Thomas方法

求解过程: set $x = d$;
for $k=2$ step until n do

$$x_k \leftarrow x_k - a_k x_{k-1}$$

end loop (k)

$$x_n \leftarrow \frac{x_n}{b_n}$$

for $k=n-1$ step until 1 do

$$x_k \leftarrow \frac{x_k - c_k x_{k+1}}{b_k}$$

end loop (k)

Thomas方法

求解过程: set $x = d$;
for $k=2$ step until n do

$$x_k \leftarrow x_k - a_k x_{k-1}$$

end loop (k)

$$x_n \leftarrow \frac{x_n}{b_n}$$

for $k=n-1$ step until 1 do

$$x_k \leftarrow \frac{x_k - c_k x_{k+1}}{b_k}$$

end loop (k)

Theorem

如果对任意 i , $|b_i| \geq |a_i| + |c_i|$ 并

且 $|b_1| > |c_1| > 0$ 和 $|b_n| > |a_n| > 0$, Thomas方法可解。计算量为 $\mathcal{O}(n)$.

消元顺序问题

不能期待在消去的过程中，非零元素变为零！也就是说，选择主元时，一般不考虑非主元元素的强度。参考J.W.H. Liu, The minimum degree ordering with constraints, SIAM J. Sci. Stat. Comput., 10(6), pp. 1136-1145, 1989.

矩阵的非对角元反应不同自由度之间的耦合关系，很多问题中，这种关系具有对称性。

最小度消去排序算法：

begin

 G:=给定的对称图;

while G is not empty, **do**

begin

 选择具有最小度的点 y , $|Adj_G(y)|$, 排在下一位置;

$G = G_y$;

end;

end

Outline

1 Action of Matrices

2 Gauss Elimination

3 Stability Analysis

矩阵的条件数

在用直接法求解 $\mathbf{Ax} = \mathbf{b}$ 的过程中,由于舍入误差的存在,必然会导致结果产生误差.因而有必要对可能产生的误差作一估计.通常我们假设在数值处理的过程中计算都是精确的.

矩阵的条件数

在用直接法求解 $\mathbf{Ax} = \mathbf{b}$ 的过程中,由于舍入误差的存在,必然会导致结果产生误差.因而有必要对可能产生的误差作一估计.通常我们假设在数值处理的过程中计算都是精确的.

Example

方程组

$$\begin{pmatrix} 3 & 1 \\ 3.0001 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 4.0001 \end{pmatrix}$$

的精确解是 $(1, 1)^T$.若 A 和 b 作如下的微小变化,

$$\begin{pmatrix} 3 & 1 \\ 2.9999 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 4.0002 \end{pmatrix}.$$

其精确解是 $(-2, 10)^T$.数据的微小变化产生解的巨大变化.

另一个例子

方程组

$$\begin{pmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 32 \\ 23 \\ 33 \\ 31 \end{pmatrix}$$

其精确解为 $(1, 1, 1, 1)^T$. 对右端向量做微小的修改

$$\begin{pmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{pmatrix} \begin{pmatrix} x_1 + \delta x_1 \\ x_2 + \delta x_2 \\ x_3 + \delta x_3 \\ x_4 + \delta x_4 \end{pmatrix} = \begin{pmatrix} 32.1 \\ 22.9 \\ 33.1 \\ 30.9 \end{pmatrix}$$

其精确解为 $x + \delta x = (9.2, -12.6, 4.5, -1.1)^T$. 若对系数矩阵做一微小的修改

$$\begin{pmatrix} 10 & 7 & 8.1 & 7.2 \\ 7.08 & 5.04 & 6 & 5 \\ 8 & 5.98 & 9.89 & 9 \\ 6.99 & 4.99 & 9 & 9.98 \end{pmatrix} \begin{pmatrix} x_1 + \Delta x_1 \\ x_2 + \Delta x_2 \\ x_3 + \Delta x_3 \\ x_4 + \Delta x_4 \end{pmatrix} = \begin{pmatrix} 32 \\ 23 \\ 33 \\ 31 \end{pmatrix}$$

其精确解为 $x + \Delta x = (-81, 137, -34, 22)^T$.

解的扰动定理

Theorem

设 $A \in \mathbf{R}^{n \times n}$, $\det A \neq 0$, x 和 $x + \delta x$ 分别满足方程组

$$\begin{aligned} Ax &= b \\ (A + \delta A)(x + \delta x) &= b + \delta b \end{aligned}$$

其中 $b \neq 0$, 而且 δA 充分小, 使

$$\frac{\|\delta A\|}{\|A\|} < \frac{1}{\text{cond}(A)}$$

则有

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A^{-1}\| \|\delta A\|} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

设 $A \in \mathbf{R}^{n \times n}$ 为可逆阵, $\|\cdot\|$ 为一种从属的矩阵范数, 则

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

称为 A 的条件数. 记 $\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2$. 类似定义 $\text{cond}_\infty(A)$ 和 $\text{cond}_1(A)$.

定理的证明

由条件知 $A + \delta A$ 可逆, 且

$$\|(A + \delta A)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\delta A\|}.$$

因为

$$x + \delta x = (A + \delta A)^{-1}(b + \delta b)$$

由此

$$\begin{aligned}\delta x &= (A + \delta A)^{-1}[b + \delta b - (A + \delta A)x] \\ &= (A + \delta A)^{-1}[-(\delta A)x + \delta b] \\ \|\delta x\| &\leq \|(A + \delta A)^{-1}\|(\|\delta A\|\|x\| + \|\delta b\|) \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\delta A\|} \left(\frac{\|\delta A\|}{\|A\|} \|A\|\|x\| + \frac{\|\delta b\|}{\|b\|} \|A\|\|x\| \right) \\ &= \frac{\|A\|\|A^{-1}\|}{1 - \|A^{-1}\|\|\delta A\|} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right) \|x\|\end{aligned}$$

矩阵相对奇异性的度量

Theorem

设矩阵 A 非奇异, 则

$$\min_{A + \delta A \text{ 奇异}} \frac{\|\delta A\|_2}{\|A\|_2} = \frac{1}{\text{cond}_2(A)}.$$

设 $\|x\|_2 = 1$, $\|A^{-1}x\|_2 = \|A^{-1}\|_2$. 令

$$y = \frac{A^{-1}x}{\|A^{-1}x\|_2} = \frac{A^{-1}x}{\|A^{-1}\|_2}, \quad \delta A = -\frac{xy^T}{\|A^{-1}\|_2}.$$

则有 $\|y\|_2 = 1$. 但

$$(A + \delta A)y = 0,$$

$$\|\delta A\|_2 = \max_{\|z\|_2=1} \left\| \frac{xy^T}{\|A^{-1}\|_2} z \right\| = \frac{\|x\|_2}{\|A^{-1}\|_2} \max_{\|z\|_2=1} |y^T z| = \frac{1}{\|A^{-1}\|_2}.$$

基于残量的误差估计

设得到 $Ax = b$ 的一个近似解 $\bar{x}$, 其残量为

$$r = b - A\bar{x}.$$

当 r 很“小”时, $\bar{x}$ 是否是准确解的一个“好”的逼近?

设 x 和 $\bar{x}$ 分别为准确解和近似解。则

$$\frac{1}{\text{cond}(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|x - \bar{x}\|}{\|x\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}.$$

只需证明第二个不等式。

$$\|x - \bar{x}\| = \|A^{-1}r\| \leq \|A^{-1}\| \|r\| = \text{cond}(A) \frac{\|r\|}{\|b\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|} \|x\|.$$

一个例子

方程组

$$\begin{pmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 32 \\ 23 \\ 33 \\ 31 \end{pmatrix}$$

系数矩阵的所有特征值为 $\lambda_1 \approx 30.2887, \lambda_2 \approx 3.858, \lambda_3 \approx 0.8431, \lambda_4 \approx 0.01015$, 故而

$$\text{cond}_2(A) = \frac{\lambda_1}{\lambda_2} \approx 2984$$

给出的例子 $b = (32, 23, 33, 31)^T, \delta b = (0.1, -0.1, 0.1, -0.1)^T, \delta x = (8.2, -13.6, 3.5, -2.1)^T$, 精确解为 $x = (1, 1, 1, 1)^T$, 所以 实际的相对误差为

$$\frac{\|\delta b\|_2}{\|b\|_2} \approx 0.003332, \quad \frac{\|\delta x\|_2}{\|x\|_2} \approx 8.198 \approx 2460 \frac{\|\delta b\|_2}{\|b\|_2}$$

条件数的性质

设 $A \in \mathbf{R}^{n \times n}$, A 非奇异, 则有

① $\text{cond}(A) \geq 1, \text{cond}(A) = \text{cond}(A^{-1}),$

$$\text{cond}(\alpha A) = \text{cond}(A), \forall \alpha \in \mathbf{R}, \alpha \neq 0$$

② 若 A 为正交阵, 则

$$\text{cond}_2(A) = 1$$

③ 若 U 为正交阵, 则

$$\text{cond}_2(A) = \text{cond}_2(AU) = \text{cond}_2(UA)$$

④ 设 λ_1 与 λ_n 为按模最大和最小的特征值, 则

$$\text{cond}(A) \geq \frac{|\lambda_1|}{|\lambda_n|}$$

若对称, 则 $\text{cond}_2(A) = \frac{|\lambda_1|}{|\lambda_n|}.$

病态矩阵

条件数大的矩阵称为病态矩阵。 Hilbert矩阵是一个著名的病态矩阵,记为

$$H_n = \begin{pmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n+1} & \cdots & \frac{1}{2n-1} \end{pmatrix}$$

它是一个正定的 $n \times n$ 的矩阵.

n	3	5	6	8	10
$\text{cond}_2(H_n)$	5×10^2	5×10^5	1.5×10^7	1.5×10^{10}	1.6×10^{12}

病态矩阵

条件数大的矩阵称为病态矩阵。 Hilbert矩阵是一个著名的病态矩阵,记为

$$H_n = \begin{pmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n+1} & \cdots & \frac{1}{2n-1} \end{pmatrix}$$

它是一个正定的 $n \times n$ 的矩阵.

n	3	5	6	8	10
$\text{cond}_2(H_n)$	5×10^2	5×10^5	1.5×10^7	1.5×10^{10}	1.6×10^{12}

条件数与数值精度

粗略地说,如果用直接法(如主元素法)解方程组 $Ax = b$,设 A 和 b 的元素准确到 s 位数字,且 $\text{cond}(A) \approx 10^t$,其中 $t < s$,则计算解向量的分量大约有 $s - t$ 位数字的准确度.

弱病态线性代数方程组的求解

主要是通过适当的变换,降低系数矩阵的条件数。

Example

方程组

$$\begin{pmatrix} 10 & 100000 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 100000 \\ 2 \end{pmatrix}$$

的准确解为 $x_1 = 1.0010001 \dots$, $x_2 = 0.99989998 \dots$, 引入 $D_1 = \text{diag}(10^{-5}, 1)$, 左乘方程得到

$$\begin{pmatrix} 0.0001 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

如果都用3位十进制的列主元消去法求解,原方程组解得 $x = (0.00, 1.00)^T$, 而后一方程组解得 $x = (1.00, 1.00)^T$. 前一方程系数矩阵的2-条件数为 1×10^5 , 而后一方程系数矩阵的2-条件数为 2.6184.