

线性代数方程组的(单步)定常线性迭代

郑春雄

清华大学数学科学系

czheng@tsinghua.edu.cn

迭代方法的基本思路

构造一个向量序列，使其尽快地收敛到线性代数方程组

$$Ax = b$$

的解。

向量序列相关性质

Definition

设 $\{x^{(k)}\}_{k=0}^{\infty}$ 是赋范空间 $(\mathbf{R}^n, \|\cdot\|)$ 中的向量序列. 若存在 $x \in \mathbf{R}^n$, 使得

$$\lim_{k \rightarrow \infty} \|x^{(k)} - x\| = 0,$$

则称 $\{x^{(k)}\}$ 收敛于 x , 记为 $\lim_{k \rightarrow \infty} x^{(k)} = x$.

Remark

上面定义的收敛性表面上看来依赖于 $\mathbf{R}^n$ 中的范数, 但由于有限维线性空间中的所有范数都是等价的, 向量序列的收敛性不依赖于范数的选择.

Theorem

设 $x^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$, $x = (x_1, x_2, \dots, x_n)^T$, 则

$$\lim_{k \rightarrow \infty} x^{(k)} = x \iff \lim_{k \rightarrow \infty} x_i^{(k)} = x_i, \quad \forall i = 1, 2, \dots, n.$$

亦即向量序列收敛等价于其分量序列收敛.

Proof.

$$\begin{aligned} \lim_{k \rightarrow \infty} x^{(k)} = x &\iff \lim_{k \rightarrow \infty} \|x^{(k)} - x\|_{\infty} = 0 \\ &\iff \lim_{k \rightarrow \infty} \max_{i=1,2,\dots,n} |x_i^{(k)} - x_i| = 0 \\ &\iff \lim_{k \rightarrow \infty} |x_i^{(k)} - x_i| = 0, \quad \forall i = 1, 2, \dots, n \\ &\iff \lim_{k \rightarrow \infty} x_i^{(k)} = x_i, \quad \forall i = 1, 2, \dots, n. \end{aligned}$$

矩阵序列

定义了范数 $\|\cdot\|$ 的空间 $\mathbf{R}^{n \times n}$ 中,若存在 $A \in \mathbf{R}^{n \times n}$,使得

$$\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0,$$

则称矩阵序列 $\{A^{(k)}\}$ 收敛于 A ,记做 $\lim_{k \rightarrow \infty} A^{(k)} = A$.

Theorem

设 $A^{(k)} = (a_{ij}^{(k)})$, $A = (a_{ij})$, 则

$$\lim_{k \rightarrow \infty} A^{(k)} = A \iff \lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}, \quad \forall i, j = 1, 2, \dots, n.$$

亦即矩阵序列收敛等价于其分量序列收敛.

Theorem

$\lim_{k \rightarrow \infty} A^{(k)} = 0$ 的充要条件是

$$\lim_{k \rightarrow \infty} A^{(k)} x = 0, \forall x \in \mathbf{R}^n.$$

Proof.

对任一矩阵的从属范数有

$$\|A^{(k)} x\| \leq \|A^{(k)}\| \|x\|.$$

必要性得证. 另一方面

$$|a_{ij}^{(k)}| = |e_i^T A^{(k)} e_j| \leq \|A^{(k)} e_j\|_{\infty} \rightarrow 0, \forall i, j = 1, 2, \dots, n.$$



幂矩阵序列

下面讨论一种特殊的矩阵序列: $\{B^k\}_{k=0}^{\infty}$, 其中 $B \in \mathbf{R}^{n \times n}$. 下面三个命题等价:

- ① $\lim_{k \rightarrow \infty} B^k = 0$.
- ② $\rho(B) < 1$.
- ③ 至少存在一种从属的矩阵范数 $\|\cdot\|$, 使 $\|B\| < 1$.

Proof.

(1) $\implies$ (2) 反设, 若 B 有一特征值 λ , 满足 $|\lambda| \geq 1$, 则有特征向量 $x \neq 0$, 满足 $Bx = \lambda x$. 由此

$$\|B^k x\| = |\lambda|^k \|x\| \not\rightarrow 0.$$

与(1)矛盾.

(2) $\implies$ (3) 由定理保证.

(3) $\implies$ (1) $\|B^k\| \leq \|B\|^k \rightarrow 0, k \rightarrow \infty$.



设 $B \in \mathcal{R}^{n \times n}$, $\|\cdot\|$ 为任意范数, 则 $\lim_{k \rightarrow \infty} \|B^k\|_1^{\frac{1}{k}} = \rho(B)$.

Proof.

$$\rho(B) = [\rho(B^k)]^{\frac{1}{k}} \leq \|B^k\|_1^{\frac{1}{k}}.$$

另一方面, 对任意的 $\epsilon > 0$, 记

$$B_\epsilon = [\rho(B) + \epsilon]^{-1} B,$$

则有 $\rho(B_\epsilon) < 1$, 从而有 $\lim_{k \rightarrow \infty} B_\epsilon^k = 0$. 故而在存在 $N = N(\epsilon) > 0$, 使得当 $k > N$ 时, 有

$$\|B_\epsilon^k\| = \frac{\|B^k\|_1}{[\rho(B) + \epsilon]^k} < 1.$$

故而当 $k > N$ 时

$$\rho(B) \leq \|B^k\|_1^{\frac{1}{k}} \leq \rho(B) + \epsilon.$$

因而 $\lim_{k \rightarrow \infty} \|B^k\|_1^{\frac{1}{k}} = \rho(B)$. 再由范数的等价性即得证。 □

线性定常迭代

设线性代数方程组

$$Ax = b$$

有唯一解.假定方程

$$x = Bx + f$$

存在唯一解,并且该解与 $Ax = b$ 的解相同,则我们可以构造一个定常的线性迭代公式

$$x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots$$

其中 $x^{(0)}$ 给定, B 称为迭代矩阵.若如此产生的序列 $\{x^{(k)}\}_{k=0}^{\infty}$ 有极限 x^* ,则 x^* 为方程 $Ax = b$ 的解,并且说如上迭代公式是收敛的.

收敛性分析

不收敛的迭代法是无价值的. 我们给出定常的线性迭代法收敛的条件.

设 x^* 是 $x = Bx + f$ 的解, 则迭代公式为

$$x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots$$

记 $e^{(k)} = x^{(k)} - x^*$, 则有

$$e^{(k+1)} = Be^{(k)}, k = 0, 1, \dots$$

从而

$$e^{(k)} = B^k e^{(0)}$$

故而迭代法收敛意味着

$$\lim_{k \rightarrow \infty} e^{(k)} = \lim_{k \rightarrow \infty} B^k e^{(0)} = 0, \forall e^{(0)} \in \mathbf{R}^n.$$

下面的命题等价

- ① 迭代法 $x^{(k+1)} = Bx^{(k)} + f$ 收敛.
- ② $\rho(B) < 1$.
- ③ 至少存在一种从属的矩阵范数 $\|\cdot\|$, 使得 $\|B\| < 1$.

误差估计

设 x^* 是方程 $x = Bx + f$ 的唯一解, $\|\cdot\|_\nu$ 是一种矩阵范数, 对应的从属的矩阵范数 $\|B\|_\nu < 1$, 则有迭代法

$$x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots$$

产生的向量序列 $\{x^{(k)}\}$ 满足

$$\|x^{(k)} - x^*\|_\nu \leq \frac{\|B\|_\nu}{1 - \|B\|_\nu} \|x^{(k)} - x^{(k-1)}\|_\nu$$

$$\|x^{(k)} - x^*\|_\nu \leq \frac{\|B\|_\nu^k}{1 - \|B\|_\nu} \|x^{(1)} - x^{(0)}\|_\nu$$

收敛速度

现假设迭代法 $x^{(k+1)} = Bx^{(k)} + f$ 收敛, 即 $\rho(B) < 1$, 我们讨论迭代的收敛速度问题. 记 $e^{(k)} = x - x^{(k)}$. 由于 $\|e^{(k)}\| \leq \|B^k\| \|e^{(0)}\|$. 现设 $e^{(0)} \neq 0$, 则有

$$\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \leq \|B^k\|$$

迭代 k 次后, 平均每次迭代误差范数的放大倍数为 $\|B^k\|^{1/k}$. 如果要求迭代 k 次后

$$\|e^{(k)}\| \leq \sigma \|e^{(0)}\|$$

其中 $\sigma > 0$ 为一小数. 由于 $\rho(B) < 1$, 故而 $\|B^k\| \rightarrow 0, k \rightarrow \infty$. 于是我们可以选择足够大的 k , 使得

$$\|B^k\| \leq \sigma.$$

对于所有使 $\|B^k\| < 1$ 的 k , 上式等价于

$$k \geq -\frac{\ln \sigma}{-\frac{1}{k} \ln \|B^k\|} = -\frac{\ln \sigma}{-\ln \|B^k\|^{1/k}}$$

$R_k(B) \stackrel{\text{def}}{=} -\ln \|B^k\|^{1/k}$ 称为迭代法的 **平均收敛率**.

如上的定义并不好处理.注意到

$$\lim_{k \rightarrow \infty} \|B^k\|^{1/k} = \rho(B).$$

$$R(B) \stackrel{\text{def}}{=} -\ln \rho(B)$$

称为迭代法的**渐进收敛率**,或**渐进收敛速度**.

显然 $R(B) = \lim_{k \rightarrow \infty} R_k(B)$,且 $R(B)$ 与 B 上取何种范数 及迭代次数无关.它反映迭代次数趋于无穷时迭代法的渐进性质.为了达到所需要的精度,可以用

$$k \approx -\ln \sigma / R(B)$$

作为迭代次数的估计.

Richardson迭代

最简单的迭代格式

$$x_{i+1} = x_i + (b - Ax_i) = x_i + r_i = (I - A)x_i + b.$$

此为Richardson迭代。收敛的条件为

$$\rho(I - A) < 1.$$

即 $\sigma(A) \subset B(1, 1)$. 注意到

$$r_{i+1} = (I - A)r_i, \quad x^* - x_{i+1} = (I - A)(x^* - x_i).$$

于是

$$r_{i+1} = (I - A)^{i+1}r_0, \quad x^* - x_{i+1} = (I - A)^{i+1}(x^* - x_0).$$

注意:

$$x_{i+1} = x_0 + r_0 + \cdots + r_i = x_0 + \sum_{j=0}^i (I - A)^j r_0 \in x_0 + \text{Span}\{r_0, \cdots, A^i r_0\}.$$

Krylov子空间

设 A 是一个非零 N 阶方阵, v 是一个非零 N -维向量. 用 A 反复作用于 v :

$$v, Av, A^2v, A^3v, \dots$$

给定 $m \geq 0$, Krylov子空间 $\mathcal{K}_m(v)$ 包含且仅包含下面的元素:

$$\sum_{k=0}^{m-1} a_k A^k v.$$

显然有

$$\mathcal{K}_1(v) \subset \mathcal{K}_2(v) \subset \dots \subset \mathcal{K}_m(v) \subset \dots$$

上述所有空间的最大维数称为 v (关于 A)的度。

性质

如果 $\mathcal{K}_m(v) = \mathcal{K}_{m+1}(v)$, 则 $\mathcal{K}_{m+1}(v) = \mathcal{K}_{m+2}(v)$.

预处理矩阵

设矩阵 M 可逆, 且 M^{-1} 是 A 逆矩阵的一个“好”近似。显然有

$$M^{-1}Ax = M^{-1}b.$$

对此方程用 Richardson 迭代:

$$x_{i+1} = x_i + M^{-1}b - M^{-1}Ax_i = x_i + M^{-1}r_i.$$

$r_i = b - Ax_i$ 称为残量 (residual). 矩阵 M 称为预处理矩阵 (或者 M^{-1} ?).

预处理矩阵的选择依据:

- “好计算” — easy to compute
- “好近似” — good approximation

设 $A = D - L - U$.

D : 对角部分。 $-L$: 严格下三角部分。 $-U$: 严格上三角部分。

① Jacobi迭代: $M = D$

$$x_{i+1}^{(k)} = \frac{1}{a_{kk}} \left(b_k - \sum_{j=1}^{k-1} a_{kj} x_i^{(j)} - \sum_{j=k+1}^n a_{kj} x_i^{(j)} \right)$$

② Gauss-Seidel(GS)迭代: $M = D - L$.

$$x_{i+1}^{(k)} = \frac{1}{a_{kk}} \left(b_k - \sum_{j=1}^{k-1} a_{kj} x_{i+1}^{(j)} - \sum_{j=k+1}^n a_{kj} x_i^{(j)} \right)$$

③ SOR(Successive Overrelaxation)方法: $M = \frac{1}{\omega}(D - \omega L)$

$$x_{i+1}^{(k)} = (1 - \omega)x_i^{(k)} + \omega \left[\frac{1}{a_{kk}} \left(b_k - \sum_{j=1}^{k-1} a_{kj} x_{i+1}^{(j)} - \sum_{j=k+1}^n a_{kj} x_i^{(j)} \right) \right]$$

J法和GS法收敛的一个充分条件

- 若 $A = (a_{ij}) \in \mathcal{R}^{n \times n}$, 满足

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

称 A 为严格对角占优矩阵. 若 A 满足

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

且其中至少有一个严格不等式成立, 则称 A 为弱对角占优矩阵.

- 若 $A \in \mathcal{R}^{n \times n}$, 不能找到排列矩阵 P , 使得

$$P^T A P = \begin{pmatrix} \bar{A}_{11} & \bar{A}_{12} \\ 0 & \bar{A}_{22} \end{pmatrix}$$

其中 $\bar{A}_{11}$ 和 $\bar{A}_{22}$ 均为方阵, 称 A 为不可约矩阵.

Theorem

若 $A = (a_{ij})$ 严格对角占优, 则 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 且 A 非奇异.

$a_{ii} \neq 0, i = 1, 2, \dots, n$ 显然. 设 A 奇异, 则存在非零向量 x , 使得 $Ax = 0$. 设 $|x_j| = \|x\|_\infty$, 则

$$\begin{aligned} 0 &= \left| \sum_{k=1}^n a_{jk} x_k \right| = \left| a_{jj} x_j + \sum_{\substack{k=1 \\ k \neq j}}^n a_{jk} x_k \right| \geq |a_{jj}| |x_j| - \sum_{\substack{k=1 \\ k \neq j}}^n |a_{jk}| |x_k| \\ &\geq |x_j| \left(|a_{jj}| - \sum_{\substack{k=1 \\ k \neq j}}^n |a_{jk}| \right) > 0 \end{aligned}$$

Theorem

若 A 不可约弱对角占优, 则 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 且 A 非奇异.

Theorem

若 A 为严格对角占优或不可约弱对角占优矩阵,则 方程组 $Ax = b$ 的 J 法和 GS 法均收敛.

对于 J 法,设 $B_J = D^{-1}(L + U)$ 有一特征值 λ ,其模值不小于1. 则由

$$\det(\lambda I - D^{-1}(L + U)) = 0$$

知

$$\det(D - \lambda^{-1}(L + U)) = 0.$$

若 A 为严格对角占优或不可约弱对角占优矩阵,则 $D - \lambda^{-1}(L + U)$ 也是严格对角占优或不可约弱对角占优矩阵.矛盾. 类似,对于 GS 法,设 $B_G = (D - L)^{-1}U$ 有一特征值 λ ,其模值不小于1.

$$\det(\lambda I - (D - L)^{-1}U) = 0$$

知

$$\det(D - L - \lambda^{-1}U) = 0.$$

若 A 为严格对角占优或不可约弱对角占优矩阵,则 $D - L - \lambda^{-1}U$ 也是严格对角占优或不可约弱对角占优矩阵.矛盾.

SOR收敛的必要条件

Theorem

对任意的 $A \in \mathbf{R}^{n \times n}$, 设其对角元素皆非零, 则对所有实数 ω , 有

$$\rho(\mathcal{L}_\omega) \geq |\omega - 1|$$

设 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 $\mathcal{L}_\omega$ 的 n 个特征值, 则

$$\begin{aligned}\lambda_1 \lambda_2 \cdots \lambda_n &= \det \mathcal{L}_\omega = \det(D - \omega L)^{-1} \det[(1 - \omega)D + \omega U] \\ &= \det D^{-1} \det[(1 - \omega)D] = (1 - \omega)^n\end{aligned}$$

因而

$$|\omega - 1|^n \leq (\max |\lambda_i|)^n,$$

进而

$$\rho(\mathcal{L}_\omega) = \max_i |\lambda_i| \geq |\omega - 1|$$

Theorem

SOR收敛的一个必要条件是 $|1 - \omega| < 1$, 即 $0 < \omega < 2$.

对称正定矩阵SOR收敛的充分必要条件

Theorem

设 $A \in \mathbf{R}^{n \times n}$ 为对称正定矩阵, 且 $0 < \omega < 2$, 则解 $Ax = b$ 的SOR方法收敛.

设 λ 是 $\mathcal{L}_\omega$ 的任一特征值, 对应的一个特征向量 x . 则由于

$$\begin{aligned}\mathcal{L}_\omega &= (D - \omega L)^{-1} [(1 - \omega)D + \omega U], \mathcal{L}_\omega x = \lambda x \\ [(1 - \omega)D + \omega U]x &= \lambda(D - \omega L)x.\end{aligned}$$

上式两边与 x 做内积, 则得

$$(1 - \omega)(Dx, x) + \omega(Ux, x) = \lambda[(Dx, x) - \omega(Lx, x)] \quad (1)$$

因为 A 正定, 故 D 正定, 记 $p = (Dx, x)$, 从而 $p > 0$. 又记 $(Lx, x) = \alpha + i\beta$, 则

$$(Ux, x) = (x, U^H x) = (x, Lx) = \overline{(Lx, x)} = \alpha - i\beta.$$

由(1)即得

$$\lambda = \frac{(1 - \omega)p + \omega\alpha - i\omega\beta}{p - \omega\alpha - i\omega\beta}, \quad |\lambda|^2 = \frac{[p - \omega(p - \alpha)]^2 + \omega^2\beta^2}{(p - \omega\alpha)^2 + \omega^2\beta^2}$$

由于

$$[p - \omega(p - \alpha)]^2 - (p - \omega\alpha)^2 = p(2 - \omega)\omega(2\alpha - p)$$

另外, 由 A 正定知

$$0 < (Ax, x) = p - (\alpha + i\beta) - (\alpha - i\beta) = p - 2\alpha$$

从而

$$[p - \omega(p - \alpha)]^2 - (p - \omega\alpha)^2 < 0$$

故 $|\lambda| < 1$. $\rho(\mathcal{L}_\omega) < 1$.

Theorem

设 A 是对称正定的三对角阵,则 $\rho(B_G) = [\rho(B_J)]^2 < 1$,且SOR迭代法的最优松弛因子为

$$\omega_{opt} = \frac{2}{1 + \sqrt{1 - [\rho(B_J)]^2}}$$

且

$$\rho(\mathcal{L}_{opt}) = \omega_{opt} - 1.$$

一个例子

考虑方程组

$$\begin{pmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 24 \\ 30 \\ -24 \end{pmatrix}$$

其精确解为 $x = (3, 4, -5)^T$. 下表列出不同迭代法所需要的迭代次数

	J	GS	$SOR_{0.8}$	SOR_{opt}	$SOR_{1.8}$
ρ	0.791	0.625	0.746	0.240	0.800
$\frac{1}{-\log_{10} \rho}$	9.8	4.9	7.9	1.6	10.3
$< 10^{-3}$	37	14	18	7	41
$< 10^{-5}$	56	23	34	11	61
$< 10^{-7}$	76	33	50	14	82
$< 10^{-9}$	95	43	65	17	102

$$\omega_{opt} = \frac{2}{1 + \sqrt{1 - [\rho(B_J)]^2}} \approx 1.24$$