

# 线性代数方程组的非线性迭代解法

郑春雄

清华大学数学科学系

[czheng@tsinghua.edu.cn](mailto:czheng@tsinghua.edu.cn)

算子方程:

$$Ax = b \in V,$$

其中 $A$ 是一个对称可逆算子 (相对于某个Hilbert空间 $V$ 中的内积):

$$(Ax, y) = (x, Ay), \quad \forall x, y \in V,$$

$$(Ax, x) \geq 0, \quad \forall x \in V,$$

$$(Ax, x) = 0 \Leftrightarrow x = 0.$$

例子

$\mathbf{R}^n$ 中的内积结构和 $N$ -阶对称正定矩阵存在一一对应. 任意给定(相应于参考内积结构)SPD矩阵 $M$ , 如下定义了一个新的内积

$$(x, y)_M = (Mx, y).$$

# Ritz变分问题

考虑二次函数  $\varphi: V \rightarrow \mathbf{R}$ , 定义为

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x).$$

① 对一切  $x \in V$ ,

$$\delta\varphi(x) = Ax - b, \quad \delta^2\varphi(x) = A$$

② 对一切  $x, y \in V, \alpha \in \mathbf{R}$ ,

$$\varphi(x + \alpha y) = \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2}(Ay, y)$$

③  $\varphi$  下方有界. 设  $x^* = A^{-1}b$  为  $Ax = b$  的解, 则

$$\varphi(x^*) = -\frac{1}{2}(b, A^{-1}b) = -\frac{1}{2}(Ax^*, x^*)$$

而且对一切  $x \in V$ , 有

$$\varphi(x) - \varphi(x^*) = \frac{1}{2}(A(x - x^*), x - x^*) = \frac{1}{2}\|x - x^*\|_A^2.$$

## Theorem

设 $A$ 对称正定, 则 $x^*$ 为 $Ax = b$ 的解的充分必要条件是 $x^*$ 满足

$$\varphi(x^*) = \min_{x \in V} \varphi(x)$$

的唯一解。其中

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x).$$

## 迭代选择策略

设计一个单步迭代方法的思想: 给定 $x^{(k)}$ , 确定 $x^{(k+1)}$ , 使得

$$\varphi(x^{(k+1)}) < \varphi(x^{(k)}).$$

# Outline

- 1 Subspace Method
- 2 Steepest Descent Method
- 3 Conjugate Gradient Method
- 4 Preconditioning

# 子空间搜索

设  $x + \Phi$  是一个仿射平面. 考虑

$$y^* = \arg \min_{y \in \Phi} \varphi(x + y).$$

则由于

$$\varphi(x + y) - \varphi(x^*) = \frac{1}{2} \|x + y - x^*\|_A^2,$$

有

$$[x^* - (x + y^*)] \perp_A \Phi.$$

于是

$$[b - A(x + y^*)] \perp \Phi.$$

# 一维极小搜索方法

设 $x^{(k)}$ 已经得到。给定搜索方向 $p^{(k)} \neq 0$ 。考虑一维极小值问题：

$$\alpha_k = \arg \min_{\alpha} \varphi(x^{(k)} + \alpha p^{(k)}), \quad x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}.$$

① 解可以显式得到

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}, \quad r^{(k)} = b - Ax^{(k)}.$$

② 如果 $(r^{(k)}, p^{(k)}) \neq 0$ ，则

$$\varphi(x^{(k+1)}) < \varphi(x^{(k)}).$$

③ 由上页的结论

$$r^{(k+1)} \perp p^{(k)}.$$

# Outline

- 1 Subspace Method
- 2 Steepest Descent Method
- 3 Conjugate Gradient Method
- 4 Preconditioning

# 最速下降法

搜索方向选择为 $x^{(k)}$ 点函数 $\varphi$ “局部”下降最快的方向 $p^{(k)} = r^{(k)}$ 。

最速下降法:

① 选取 $x^{(0)} \in \mathbf{R}^n$

② 对 $k = 0, 1, \dots$

$$r^{(k)} = b - Ax^{(k)}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$

# 最速下降法的性质

- ① 相邻两次搜索方向是正交的,即

$$(r^{(k+1)}, r^{(k)}) = 0$$

②

$$r^{(k+1)} = r^{(k)} - \alpha_k A r^{(k)} = (I - \alpha_k A) r^{(k)}.$$

- ③  $\{\varphi(x^{(k)})\}$  是单调下降有下界的序列,它存在极限,并且

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* = A^{-1}b$$

- ④ 记  $e^{(k)} = x^{(k)} - x^*$ , 则

$$\sqrt{(Ae^{(k)}, e^{(k)})} \leq \left( \frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \sqrt{(Ae^{(0)}, e^{(0)})}$$

其中  $\lambda_1$  和  $\lambda_n$  分别是对称正定算子  $A$  的最大最小特征值.

记  $e^{(k)} = x^{(k)} - x^*$ , 则  $Ae^{(k)} = -r^{(k)}$ . 于是

$$\begin{aligned} \|e^{(k+1)}\|_A^2 &= \|e^{(k)} + \alpha_k r^{(k)}\|_A^2 \\ &= \|e^{(k)}\|_A^2 + \|\alpha_k r^{(k)}\|_A^2 + 2\alpha_k (e^{(k)}, r^{(k)})_A \\ &= \|e^{(k)}\|_A^2 + \|\alpha_k r^{(k)}\|_A^2 - 2\alpha_k \|r^{(k)}\|^2 \\ &= \|e^{(k)}\|_A^2 - \frac{\|r^{(k)}\|^4}{\|r^{(k)}\|_A^2} \\ &= \|e^{(k)}\|_A^2 \left( 1 - \frac{\|r^{(k)}\|^4}{\|r^{(k)}\|_A^2 \|r^{(k)}\|_{A^{-1}}^2} \right) \end{aligned}$$

记  $e^{(k)} = x^{(k)} - x^*$ , 则  $Ae^{(k)} = -r^{(k)}$ . 于是

$$\begin{aligned}
 \|e^{(k+1)}\|_A^2 &= \|e^{(k)} + \alpha_k r^{(k)}\|_A^2 \\
 &= \|e^{(k)}\|_A^2 + \|\alpha_k r^{(k)}\|_A^2 + 2\alpha_k (e^{(k)}, r^{(k)})_A \\
 &= \|e^{(k)}\|_A^2 + \|\alpha_k r^{(k)}\|_A^2 - 2\alpha_k \|r^{(k)}\|^2 \\
 &= \|e^{(k)}\|_A^2 - \frac{\|r^{(k)}\|^4}{\|r^{(k)}\|_A^2} \\
 &= \|e^{(k)}\|_A^2 \left( 1 - \frac{\|r^{(k)}\|^4}{\|r^{(k)}\|_A^2 \|r^{(k)}\|_{A^{-1}}^2} \right)
 \end{aligned}$$

### Lemma

设  $B$  是对称正定算子, 则

$$\frac{(Bx, x)(B^{-1}x, x)}{(x, x)^2} \leq \frac{(\lambda_{\max} + \lambda_{\min})^2}{4\lambda_{\max}\lambda_{\min}}, \quad \forall x \neq 0.$$

只考虑 $B$ 有有限点谱的情况。设 $\|x\| = 1$  且  $x = (x_1, x_2, \dots, x_n)^T$ . 则

$$\frac{(Bx, x)(B^{-1}x, x)}{(x, x)^2} = \sum_{i=1}^n x_i^2 \lambda_i \sum_{i=1}^n x_i^2 \frac{1}{\lambda_i}$$

由于

$$\frac{1}{\lambda_i} \leq \frac{1}{\lambda_{\min}} + \frac{1}{\lambda_{\max}} - \frac{\lambda_i}{\lambda_{\min} \lambda_{\max}}$$

则

$$\begin{aligned} \frac{(Bx, x)(B^{-1}x, x)}{(x, x)^2} &\leq \sum_{i=1}^n x_i^2 \lambda_i \left( \frac{1}{\lambda_{\min}} + \frac{1}{\lambda_{\max}} - \frac{\sum_{i=1}^n x_i^2 \lambda_i}{\lambda_{\min} \lambda_{\max}} \right) \\ &\leq \frac{(\lambda_{\max} + \lambda_{\min})^2}{4\lambda_{\max} \lambda_{\min}} \end{aligned}$$

# Outline

- 1 Subspace Method
- 2 Steepest Descent Method
- 3 Conjugate Gradient Method
- 4 Preconditioning

# 共轭梯度法 Conjugate Gradient

我们还是采用一维极小搜索的想法, 但不再沿有正交性的  $r^{(0)}, r^{(1)}, \dots$  方向进行搜索, 而是沿着另一组向量方向  $p^{(0)}, p^{(1)}, \dots$ . 设已经沿  $p^{(0)}, p^{(1)}, \dots, p^{(k-1)}$  做了  $k$  次一维搜索, 求得了  $x^{(k)}, r^{(k)} = b - Ax^{(k)}$ . 下一步确定搜索方向  $p^{(k)}$ , 再通过求解一维极小问题

$$x^{(k+1)} = \arg \min_{x \in x^{(k)} + \text{span}(p^{(k)})} \varphi(x)$$

来确定  $x^{(k+1)}$ . 已知:

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}, \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)}, \\ r^{(k+1)} &= b - Ax^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}.\end{aligned}$$

# 搜索方向 $p^{(k)}$ 的确定

- 开始时可取 $p^{(0)} = r^{(0)}$ ;
- 一般 $k \geq 1$ 时 $p^{(k)}$ 的确定,我们希望如下一维极小搜索的解

$$x^{(k+1)} = \arg \min_{x \in x^{(k)} + \text{span}(p^{(k)})} \varphi(x)$$

同时是如下的多维极小搜索问题的解

$$x^{(k+1)} = \arg \min_{x \in x^{(0)} + \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k)})} \varphi(x).$$

- Too ambitious! Is it possible?

# 多维子空间搜索问题

设  $x \in x^{(0)} + \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k)})$ , 则可记成

$$x = x^{(0)} + y + \alpha p^{(k)}, y \in \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k-1)}), \alpha \in \mathbf{R}$$

因而有

$$\begin{aligned}\varphi(x) &= \varphi(x^{(0)} + y + \alpha p^{(k)}) \\ &= \varphi(x^{(0)} + y) + \alpha(Ay, p^{(k)}) - \alpha(r^{(0)}, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)})\end{aligned}$$

上式中出现了交叉项. 为简化问题, 自然可考虑使

$$(Ay, p^{(k)}) = 0, \forall y \in \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k-1)})$$

即要求

$$(Ap^{(j)}, p^{(k)}) = 0, \forall k = 1, 2, \dots, \forall j = 0, 1, \dots, k-1.$$

满足如上条件的向量组称为A-正交向量组

现在假设搜索方向 $\{p^{(0)}, p^{(1)}, \dots\}$ 是A-正交的。设 $x^{(k)}$ 为前一步极小问题的解,即

$$\varphi(x^{(k)}) = \min_{x \in x^{(0)} + \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k-1)})} \varphi(x)$$

因而

$$\begin{aligned} \min_{x \in x^{(0)} + \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k)})} \varphi(x) &= \min_{y, \alpha} \varphi(x^{(0)} + y + \alpha p^{(k)}) \\ &= \min_y \varphi(x^{(0)} + y) \\ &\quad + \min_{\alpha} \left[ \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)}) - \alpha(r^{(0)}, p^{(k)}) \right] \end{aligned}$$

第一个极小化问题的解为 $y = x^{(k)}$ ,第二个问题解

$$\alpha = \alpha_k = \frac{(r^{(0)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

因为  $x^{(k)} \in x^{(0)} + \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k-1)})$ ,  
故  $(Ax^{(k)}, p^{(k)}) = (Ax^{(0)}, p^{(k)})$ , 所以

$$\alpha_k = \frac{(r^{(0)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(b - Ax^{(0)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(b - Ax^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

总体算法为

- ①  $p^{(0)} = r^{(0)}$ .
- ② 从  $x^{(k)}$  出发, 沿着  $p^{(k)}$  方向做一维极小搜索, 得到

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

其中

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

并且确定

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

- ③ **确定  $p^{(k+1)}$** , 若它与所有  $p^{(0)}, p^{(1)}, \dots, p^{(k)}$  A-正交, 转到第二步.

# CG法搜索方向的确定

- 依据子空间搜索的性质, 我们总是有

$$(r^{(k)}, p^{(j)}) = 0, \quad \forall j = 0, 1, \dots, k-1.$$

- 若  $r^{(k)} \neq 0$ , 则  $\{r^{(k)}, p^{(0)}, \dots, p^{(k-1)}\}$  线性无关. CG法取

$$p^{(k)} = r^{(k)} - \sum_{j=0}^{k-1} \frac{(r^{(k)}, p^{(j)})_A}{(p^{(j)}, p^{(j)})_A} p^{(j)}.$$

## 性质

$$(r^{(k)}, p^{(j)})_A = 0, \quad j = 0, 1, \dots, k-2.$$

记

$$\Phi_k = \text{span}(p^{(0)}, p^{(1)}, \dots, p^{(k-1)}) = \text{span}(r^{(0)}, r^{(1)}, \dots, r^{(k-1)}).$$

则  $r^{(k)} \perp r^{(j)}, j = 0, 1, \dots, k-1$ . 因而

$$Ap^{(j)} = \frac{1}{\alpha_j} (r^{(j+1)} - r^{(j)}) \perp r^{(k)}, \quad j = 0, 1, \dots, k-2.$$

$$\text{令 } p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)}, \quad \beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})}.$$

## $\alpha_k$ 的另一表达式

回顾剩余向量与一维搜索方向直交，有

$$(r^{(k)}, p^{(k)}) = (r^{(k)}, r^{(k)} + \beta_{k-1} p^{(k-1)}) = (r^{(k)}, r^{(k)})$$

于是还有

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})}$$

此外

$$\begin{aligned}\beta_k &= -\frac{(r^{(k+1)}, Ap^{(k)})}{(p^{(k)}, Ap^{(k)})} \\&= -\frac{(r^{(k+1)}, \alpha_k^{-1}(r^{(k)} - r^{(k+1)}))}{(p^{(k)}, Ap^{(k)})} \\&= \frac{\alpha_k^{-1}(r^{(k+1)}, r^{(k+1)})}{(p^{(k)}, Ap^{(k)})} \\&= \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}.\end{aligned}$$

# 完整的CG算法

- ① 任取  $x^{(0)} \in V$ ,
- ②  $r^{(0)} = b - Ax^{(0)}, p^{(0)} = r^{(0)}$ ,
- ③ 对  $k = 0, 1, \dots$

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= r^{(k)} - \alpha_k Ap^{(k)} \\ \beta_k &= \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})} \\ p^{(k+1)} &= r^{(k+1)} + \beta_k p^{(k)}\end{aligned}$$

在计算的过程中,当  $r^{(k)} = 0$  时,计算中止.

设 $\lambda_1$ 和 $\lambda_n$ 分别为 $A$ 的最大和最小特征值, 则

$$\|x^{(k)} - x^*\|_A \leq 2 \left[ \frac{\sqrt{\lambda_1} - \sqrt{\lambda_n}}{\sqrt{\lambda_1} + \sqrt{\lambda_n}} \right]^k \|x^{(0)} - x^*\|_A.$$

Proof.

$$\begin{aligned} \frac{\|x^{(k)} - x^*\|_A}{\|x^{(0)} - x^*\|_A} &= \min_{p_{k-1} \in P_{k-1}} \frac{\|p_{k-1}(A)r_0 - A^{-1}r_0\|_A}{\|A^{-1}r_0\|_A} \\ &\leq \min_{p_{k-1} \in P_{k-1}} \sup_{y \neq 0} \frac{\|p_{k-1}(A)Ay - y\|_A}{\|y\|_A} \\ &= \min_{p_k \in P_k, p_k(0)=1} \sup_{y \neq 0} \frac{\|p_k(A)y\|_A}{\|y\|_A} \\ &= \min_{p_k \in P_k, p_k(0)=1} \max_{\lambda \in \rho(A)} |p_k(\lambda)| \leq \min_{p_k \in P_k, p_k(0)=1} \|p_k\|_{C[\lambda_1, \lambda_n]} \end{aligned}$$

# 误差估计

设 $\lambda_1$ 和 $\lambda_n$ 分别为 $A$ 的最大和最小特征值, 则

$$\|x^{(k)} - x^*\|_A \leq 2 \left[ \frac{\sqrt{\lambda_1} - \sqrt{\lambda_n}}{\sqrt{\lambda_1} + \sqrt{\lambda_n}} \right]^k \|x^{(0)} - x^*\|_A.$$

Proof.

记 $\alpha = \frac{\lambda_n}{\lambda_1}$ , 取( $T_k$ 为Chebyshev多项式)

$$p_k^*(x) = \frac{T_k\left(\frac{2x-(1+\alpha)}{1-\alpha}\right)}{T_k\left(-\frac{1+\alpha}{1-\alpha}\right)}.$$

则

$$\|p_k^*\|_{L^\infty(\alpha,1)} = \frac{1}{T_k\left(-\frac{1+\alpha}{1-\alpha}\right)}.$$

由于

$$T_k(t) = \frac{1}{2} \left[ \left( t + \sqrt{t^2 - 1} \right)^k + \left( t - \sqrt{t^2 - 1} \right)^k \right], \quad |t| \geq 1,$$

设 $\lambda_1$ 和 $\lambda_n$ 分别为 $A$ 的最大和最小特征值, 则

$$\|x^{(k)} - x^*\|_A \leq 2 \left[ \frac{\sqrt{\lambda_1} - \sqrt{\lambda_n}}{\sqrt{\lambda_1} + \sqrt{\lambda_n}} \right]^k \|x^{(0)} - x^*\|_A.$$

Proof.

因而

$$T_k(t) \gtrsim \frac{1}{2} \left( |t| + \sqrt{t^2 - 1} \right)^k, \quad |t| \geq 1.$$

进而

$$\|p_k^*\|_{L^\infty(\alpha, 1)} \leq 2 \left( \frac{1+\alpha}{1-\alpha} - \sqrt{\left( \frac{1+\alpha}{1-\alpha} \right)^2 - 1} \right)^k = 2 \left( \frac{1-\sqrt{\alpha}}{1+\sqrt{\alpha}} \right)^k.$$



# Outline

- 1 Subspace Method
- 2 Steepest Descent Method
- 3 Conjugate Gradient Method
- 4 Preconditioning

# 预处理的重要性

- 从误差估计

$$\sqrt{(Ae^{(k)}, e^{(k)})} \leq 2 \left[ \frac{\sqrt{\lambda_1} - \sqrt{\lambda_n}}{\sqrt{\lambda_1} + \sqrt{\lambda_n}} \right]^k \sqrt{(Ae^{(0)}, e^{(0)})}.$$

可以看出, CG法的效率强烈依赖于矩阵 $A$ 的最大最小特征值的比率.

- 设 $A$ 关于内积 $(\cdot, \cdot)$ 是SPD的. 给定关于此内积的另一个SPD矩阵 $M$ . 则

$$Ax = b \Leftrightarrow M^{-1}Ax = M^{-1}b.$$

矩阵 $M^{-1}A$ 关于内积

$$(x, y)_M = (Mx, y)$$

是SPD的.

# 对预处理后的方程应用CG算法

- ① 任取  $x^{(0)} \in V$ ,
- ②  $r^{(0)} = M^{-1}(b - Ax^{(0)})$ ,  $p^{(0)} = r^{(0)}$ ,
- ③ 对  $k = 0, 1, \dots$

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, r^{(k)})_M}{(p^{(k)}, M^{-1}Ap^{(k)})_M} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= r^{(k)} - \alpha_k M^{-1}Ap^{(k)} \\ \beta_k &= \frac{(r^{(k+1)}, r^{(k+1)})_M}{(r^{(k)}, r^{(k)})_M} \\ p^{(k+1)} &= r^{(k+1)} + \beta_k p^{(k)}\end{aligned}$$

- ④ 在计算的过程中, 当  $r^{(k)} = 0$  时, 计算中止.
- ⑤ 误差分析 ( $\mu_1$  和  $\mu_n$  是  $M^{-1}A$  的最大最小特征值)

$$\sqrt{(M^{-1}Ae^{(k)}, e^{(k)})_M} \leq 2 \left[ \frac{\sqrt{\mu_1} - \sqrt{\mu_n}}{\sqrt{\mu_1} + \sqrt{\mu_n}} \right]^k \sqrt{(M^{-1}Ae^{(0)}, e^{(0)})_M}.$$

# 对预处理后的方程应用CG算法

- ① 任取  $x^{(0)} \in V$ ,
- ②  $r^{(0)} = M^{-1}(b - Ax^{(0)})$ ,  $p^{(0)} = r^{(0)}$ ,
- ③ 对  $k = 0, 1, \dots$

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, r^{(k)})_M}{(p^{(k)}, Ap^{(k)})} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= r^{(k)} - \alpha_k M^{-1} A p^{(k)} \\ \beta_k &= \frac{(r^{(k+1)}, r^{(k+1)})_M}{(r^{(k)}, r^{(k)})_M} \\ p^{(k+1)} &= r^{(k+1)} + \beta_k p^{(k)}\end{aligned}$$

- ④ 在计算的过程中, 当  $r^{(k)} = 0$  时, 计算中止.
- ⑤ 误差分析 ( $\mu_1$  和  $\mu_n$  是  $M^{-1}A$  的最大最小特征值)

$$\sqrt{(Ae^{(k)}, e^{(k)})} \leq 2 \left[ \frac{\sqrt{\mu_1} - \sqrt{\mu_n}}{\sqrt{\mu_1} + \sqrt{\mu_n}} \right]^k \sqrt{(Ae^{(0)}, e^{(0)})}.$$

- ① 任取  $x^{(0)} \in V$ ,
- ②  $r^{(0)} = b - Ax^{(0)}, p^{(0)} = M^{-1}r^{(0)}$ ,
- ③ 对  $k = 0, 1, \dots$

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, M^{-1}r^{(k)})}{(p^{(k)}, Ap^{(k)})} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= r^{(k)} - \alpha_k Ap^{(k)} \\ \beta_k &= \frac{(r^{(k+1)}, M^{-1}r^{(k+1)})}{(r^{(k)}, M^{-1}r^{(k)})} \\ p^{(k+1)} &= M^{-1}r^{(k+1)} + \beta_k p^{(k)}\end{aligned}$$

- ④ 在计算的过程中, 当  $r^{(k)} = 0$  时, 计算中止.

# 预处理矩阵的选择和设计

设计原则: 好计算, 好近似

- 代数方法:

$$A = LL^\dagger$$

保证 $L$ 的稀疏性, 近似LU(Cholesky)分解:

$$A \approx \tilde{L}\tilde{L}^\dagger = M$$

- 分析方法: 谱等价

$$c_1(Ax, x) \leq (Mx, x) \leq c_2(Ax, x), \quad \forall x$$

则

$$\lambda(M^{-1}A) \in [c_2^{-1}, c_1^{-1}].$$